

ANONIMIZADOR — cobertura y limitaciones

ANONIMIZADOR reduce información identificable pero no garantiza anonimización absoluta. Revise siempre el documento antes de compartirlo. La aprobación final corresponde a una persona.

Este documento distingue tres cosas y no las mezcla:

- IMPLEMENTADO — está en el código, se ejecuta y hay un test que lo comprueba.
- PARCIAL — funciona, pero con un alcance recortado que se explica.
- NO IMPLEMENTADO — está diseñado o previsto, pero **no existe** todavía.

Versión: **1.0.0** · Fecha de esta revisión: **17 de agosto de 2026** · Entorno de verificación: Windows 11, Python 3.12.4, sin Tesseract instalado.

V1 — LO QUE FUNCIONA AHORA

Protocolo y arquitectura

Elemento	Estado	Detalle
A — Aclare la finalidad	IMPLEMENTADO	4 finalidades configurables; por defecto <i>Educación / discusión académica</i> . Cambia qué se generaliza.
N — No cargue el original	IMPLEMENTADO	Se calcula SHA-256, se copia a un área aislada y solo se trabaja sobre la copia . Al final se vuelve a comprobar el hash del original. Test: <code>test_original_intacto</code> .
Procesamiento local	IMPLEMENTADO	Sin red, sin API externa, sin telemetría. <code>ALLOW_NETWORK=False</code> , <code>ENABLE_LLM=False</code> , <code>ENABLE_TELEMETRY=False</code> . Test: <code>test_no_hay_red_ni_ia_por_defecto</code> .
T — Tamice identificadores (5 capas)	IMPLEMENTADO / PARCIAL	Ver tabla siguiente.
Regla clínica innegociable	IMPLEMENTADO	Antes de reescribir nada se calculan <i>spans protegidos</i> ; una transformación que los pise se bloquea y se manda a revisión.
Extraer y reconstruir	IMPLEMENTADO (TXT, DOCX) / PARCIAL (PDF, XLSX, imagen)	Ver "Formatos".
Verificación (integridad, alucinaciones, adversarial)	IMPLEMENTADO	Cuatro veredictos independientes en cada ejecución.
Riesgo residual explicable	IMPLEMENTADO	5 niveles; siempre con la lista de motivos. Nunca dice "100 % anonimizado".
Aprobación humana	IMPLEMENTADO	4 estados; la decisión se graba en <code>audit.json</code> y en <code>revisión_humana.json</code> .
Expediente de auditoría	IMPLEMENTADO	<code>audit.json</code> , <code>transformation_matrix.csv</code> , <code>integrity_report.json</code> , <code>adversarial_scan.json</code> , <code>audit_report.html</code> , <code>RESUMEN.md</code> .
Interfaz para no técnicos	IMPLEMENTADO	Streamlit local: arrastrar finalidad ANALIZAR GENERAR aprobar/rechazar.

Elemento	Estado	Detalle
Expediente multi-archivo	IMPLEMENTADO	Varios archivos se procesan juntos; cada uno con su propia auditoría (los seudónimos no se comparten entre archivos, ver limitaciones).
Modo demostración	IMPLEMENTADO	5 casos sintéticos generados al vuelo, sin ningún dato real.
Capa de IA opcional	NO IMPLEMENTADO (a propósito)	Existe la interfaz Proveedor LLM, apagada y sin ninguna implementación. V1 es 100 % determinista.

Las cinco capas de tamizado

Capa	Estado	Qué detecta hoy
1. Directos	IMPLEMENTADO	Correo, URL, IP, usuario de red, documento de identidad (CC/TI/CE/NIT/DNI/RUT/CURP/pasaporte), historia clínica, números administrativos (orden, autorización, factura, póliza, afiliado, cama...), teléfono etiquetado y teléfono móvil, dirección postal, código postal, firma/registro médico, nombres por etiqueta (Paciente:, Acompañante:, Madre:, Elaborado por:...), nombres tras tratamiento (Dr., Dra., Lic.) y nombres por léxico.
2. Indirectos	IMPLEMENTADO	Edad exacta, fecha de nacimiento, fechas, ocupación/cargo, institución (hospital, clínica, IPS, laboratorio...), aseguradora/EPS, localidad y departamento.
3. Contextuales	PARCIAL	Se puntúa la combinación residual de cuasi-identificadores y se alerta a partir de un umbral. No hay cálculo de k-anonimato ni contraste contra un padrón poblacional.
4. Visuales	PARCIAL	QR y códigos de barras: detección y destrucción real de píxeles, con verificación posterior. Regiones con aspecto de texto: detección morfológica. Leer ese texto requiere OCR (ver abajo). Como salida práctica se puede borrar la banda superior/inferior de la imagen, donde suele estar quemado el identificador. Logos y firmas manuscritas: no se reconocen como tales.
5. Técnicos	IMPLEMENTADO	Nombre del archivo, propiedades core/app/custom de OOXML, comentarios y sus autores, control de cambios y sus autores, relaciones externas, notas al pie, metadatos y XMP de PDF, anotaciones, campos de formulario, archivos embebidos, marcadores activos (/JavaScript, /OpenAction, /Launch...), EXIF y chunks de texto de PNG, propiedades de XLSX.

Formatos

Formato	Reconstrucción	Estado	Qué se conserva / qué se pierde
.txt / .md	Completa	IMPLEMENTADO	Texto íntegro reescrito desde cero.
.docx	Completa	IMPLEMENTADO	Se reconstruye con párrafos, títulos y tablas, más anexos con el texto de encabezados y pies. No se copian: comentarios, control de cambios, macros, objetos embebidos, imágenes, propiedades, plantillas, miniatura. Verificado: los identificadores no aparecen ni en el XML interno del ZIP.
.pdf	Parcial (solo texto)	PARCIAL	Se genera un PDF nuevo con reportlab. No se copian: imágenes, anotaciones, formularios, QR, capas, objetos ni metadatos. Un PDF escaneado se marca NO EVALUABLE y no se da por bueno.
.png / .jpg	Parcial (píxeles)	PARCIAL	Se reescribe la imagen sin EXIF/XMP. QR y barcodes se destruyen de verdad. Las regiones con aspecto de texto no se borran por defecto (ver "la decisión difícil").
.xlsx	Parcial (valores)	PARCIAL	Valores de texto minimizados y números copiados sin tocar. No se copian: fórmulas, comentarios de celda, formato, gráficos, imágenes, macros.

Verificaciones automáticas

Verificación	Estado	Qué hace
Integridad clínica de la transformación	IMPLEMENTADO	Compara original vs. minimizado a nivel de valor atómico (número+unidad, analito=valor, signo vital, dosis, medida, porcentaje, anatomía, lateralidad, medicamento, procedimiento, diagnóstico, negación, certeza) y clasifica en EXACT_MATCH, EXPECTED_TRANSFORMATION, UNEXPECTED_CHANGE, MISSING, NEW_CONTENT.
Integridad de la reconstrucción	IMPLEMENTADO	Compara lo que se quiso escribir con lo que se puede volver a leer del archivo generado. Atrapa pérdidas del escritor de formato.
Detección de alucinaciones	IMPLEMENTADO	Marca todo valor clínico del resultado que el original no respalda, y localiza la frase donde aparece.
Prueba adversarial	IMPLEMENTADO	Reabre el archivo generado y vuelve a atacarlo: texto, metadatos, comentarios, XML, anotaciones, QR y nombre del archivo. Una fuga baja el estado a REQUIRES_MANUAL_REVIEW y señala el módulo responsable .

Seguridad

IMPLEMENTADO: sin eval; no se ejecutan macros ni JavaScript de PDF; no se abre ninguna URL (tampoco la de un QR); no se confía en la extensión (se valida la firma binaria); límite de tamaño de archivo, de páginas de PDF y de píxeles de imagen; nombres de archivo saneados; directorio de trabajo aislado; archivos corruptos se reportan sin ejecutarse; el archivo de salida se nombra de forma neutra.

La decisión difícil de V1, explicada

Hay dos sitios donde ANONIMIZADOR **prefiere no tocar** y pedir revisión humana, porque la regla clínica está por encima de la privacidad automática:

- **Candidatos a nombre de baja confianza.** Una secuencia capitalizada que no está en el léxico de nombres podría ser un nombre... o una marca comercial de un fármaco, o un epónimo (*maniobra de Valsalva*). Borrarla a ciegas sería alterar la información clínica. Por eso se marca, sube el riesgo a MODERADO y se pide revisión. Puede forzarse la sustitución con la casilla "*Sustituir también candidatos a nombre de baja confianza*".
- **Texto dentro de los píxeles de una imagen.** Sin OCR no se puede saber si esa franja de texto es el nombre del paciente o una escala de medida. Se detecta la región, se informa y se pide revisión. Puede forzarse la redacción con la casilla "*Redactar TODAS las regiones con aspecto de texto*", asumiendo que puede tapar parte de la imagen.

En ambos casos el sistema **dice lo que hizo y lo que no hizo**. No simula que quedó resuelto.

Limitaciones conocidas de V1 (léalas antes de confiar)

- **OCR no está instalado en este equipo.** pytesseract está en las dependencias, pero el binario Tesseract no. Sin él, el texto quemado en una imagen se detecta como región pero **no se puede leer ni clasificar**. Instrucciones de instalación en el README.
- **Las imágenes de un DOCX o de un PDF no se transfieren al resultado** y sus píxeles no se analizan. Se avisa con una alerta. Si la imagen importa clínicamente, hay que exportarla y procesarla como archivo de imagen.
- **PDF escaneado:** se detecta y se marca NO EVALUABLE. V1 no lo resuelve.
- **Nombres no cubiertos por el léxico:** los léxicos son listas explícitas y cortas (~120 nombres de pila, ~70 apellidos). Un apellido poco frecuente que aparezca sin etiqueta y sin tratamiento cae en "posible nombre" revisión humana, no eliminación automática.
- **Riesgo contextual:** se puntúa la combinación, pero no hay k-anonimato real. Un caso raro (enfermedad infrecuente + institución + fecha) puede seguir siendo identificable aunque el informe diga riesgo BAJO. **Esto es exactamente para lo que existe la revisión humana.**
- **Los seudónimos no se comparten entre archivos** de un mismo expediente: [PERSONA 2] en un documento no es necesariamente [PERSONA 2] en otro.
- **Firmas manuscritas, logotipos y sellos** dentro de imágenes no se reconocen como tales.
- **No hay DICOM.** Un .dcm no se acepta.
- **El HTML de auditoría contiene los datos clínicos preservados** (que no son identificadores), por diseño, para poder revisarlos. Tráelo como material clínico, no lo publique sin más.
- RTF, ODT, PPTX, EML, MSG, CSV, ZIP, **audio y vídeo:** no soportados.
- **La detección está afinada para español clínico de LatAm/España.** En otro idioma la cobertura cae mucho.

V2 — SIGUIENTE NIVEL (viable, requiere más desarrollo)

NO IMPLEMENTADO todo lo de esta sección.

- OCR local empaquetado (Tesseract embebido o easyocr), con clasificación de cada palabra reconocida y redacción **selectiva** solo de las que sean identificadores.
- Transferir imágenes al DOCX/PDF reconstruido **después** de pasarlas por el pipeline de imagen, en lugar de descartarlas.
- Capa de PDF escaneado: rasterizar OCR reconstruir PDF con texto.
- Seudónimos coherentes en todo un expediente (mismo paciente = misma etiqueta en 12 archivos).
- Formatos: PPTX, ODT, RTF, CSV, EML/MSG con adjuntos.
- Diccionarios de nombres ampliables por el usuario desde la interfaz, con lista blanca clínica.
- Detección de firmas manuscritas y logotipos por plantilla.
- Cálculo de k-anonimato sobre un lote (no sobre un documento suelto).
- Perfiles de finalidad editables y guardables por institución.
- Modo lote por línea de comandos con informe consolidado del expediente.
- Comparador visual ANTES/DESPUÉS con resaltado de diferencias palabra a palabra.
- Firma criptográfica del expediente de auditoría (para que no se pueda alterar a posteriori).

V3 — NIVEL PROFESIONAL / INSTITUCIONAL

NO IMPLEMENTADO. Requiere presupuesto, infraestructura y, sobre todo, decisiones legales y de gobierno del dato que no le corresponden a una herramienta.

- **DICOM**: desidentificación de cabeceras según DICOM PS3.15 Anexo E, *burned-in annotation*, overlays, secuencias privadas, UID remapping consistente.
- **Integración PACS / HIS / HL7 / FHIR**.
- **Modelos NER clínicos** en español (transformer local) como capa *sugerente*, siempre validada por las reglas deterministas.
- **Modelos de visión** para detectar texto, firmas y logotipos en imágenes médicas.
- Procesamiento masivo (miles de documentos), colas, paralelismo, reintentos.
- Autenticación, roles, trazabilidad por usuario, auditoría institucional centralizada.
- Cifrado en reposo y en tránsito, gestión de claves, borrado seguro certificado.
- Políticas organizacionales: retención, finalidad declarada, consentimiento, DPIA.
- **Revisión jurídica y regulatoria** (Ley 1581/2015 y Resolución 1995/1999 en Colombia, RGPD en la UE, HIPAA *Safe Harbor / Expert Determination* en EE. UU.). ANONIMIZADOR **no** certifica el cumplimiento de ninguna de ellas.
- Validación clínica formal: medir sensibilidad/especificidad de la detección contra un corpus anotado por profesionales.

Cómo comprobar usted mismo lo que dice este documento

```
python -m pytest tests -q          # 49 pruebas
python -m anonimizador.cli --demo  # procesa los 5 casos sintéticos e imprime los veredictos
```

Cada ejecución deja su propio expediente en `reports/<id>/`. Ábralo: `audit_report.html`.