

ANONIMIZADOR — informe para profesionales de la salud

Versión 1.0.0 · documento pensado para leerse sin saber programar.

ANONIMIZADOR reduce información identificable pero no garantiza anonimización absoluta. Revise siempre el documento antes de compartirlo. La aprobación final corresponde a una persona.

1. Qué hace

Usted arrastra un documento clínico. ANONIMIZADOR le devuelve **una versión nueva del documento**, reconstruida y minimizada, más un **informe de auditoría** que explica, línea por línea, qué se quitó, qué se generalizó, qué se conservó y **por qué**.

Lo que **no** hace, y conviene decirlo primero:

- No diagnostica. No opina sobre el caso.
- No reescribe la historia clínica "con sus palabras".
- No promete que el paciente sea irreconocible.
- No sustituye su criterio ni el de un comité de ética.

Su objetivo es convertir un procedimiento repetitivo y fácil de olvidar —quitar el nombre, el documento, la fecha, la EPS, el pie de página, los metadatos de Word— en algo sistemático, verificable y con rastro escrito.

2. Cómo funciona, en una frase

Extrae todo el contenido del archivo (incluido lo que no se ve), **clasifica** cada dato, **minimiza** solo lo identificador, **reconstruye** un archivo limpio desde cero, **compara** el antes con el después, **se ataca a sí mismo** para ver si algo sobrevivió, y **le pide a usted** que apruebe o rechace.

ORIGINAL → EXTRACCIÓN → DETECCIÓN → TRANSFORMACIÓN → RECONSTRUCCIÓN
→ COMPARACIÓN → AUDITORÍA → REVISIÓN HUMANA

3. El protocolo "ANTES"

A — Aclare la finalidad

Antes de tocar nada, la herramienta le pregunta **para qué** va a usar el material. No es burocracia: cambia el resultado.

Finalidad	Qué hace distinto
Educación / discusión académica (<i>por defecto</i>)	Edad en décadas, fechas como Día 1/Día 2, sin institución ni lugar preciso.
Publicación / caso clínico escrito	Igual, y con criterio más estricto.
Interconsulta / segunda opinión	Conserva la edad y las fechas exactas , porque pueden cambiar la interpretación clínica; avisa de que eso sube el riesgo.
Investigación / dataset interno	Minimización fuerte y consistente. No sustituye la aprobación del comité.

El principio es *minimización*: se conserva **solo lo necesario para esa finalidad**.

N — No cargue el original

Regla absoluta: **el archivo original nunca se modifica**. El sistema calcula su huella digital (SHA-256), hace una copia en un área aislada, trabaja únicamente sobre la copia, genera un archivo nuevo y, al terminar, vuelve a calcular la huella del original para demostrar que sigue idéntico. Ese hash queda escrito en el informe.

Además, **todo ocurre en su computador**. No hay nube, no hay servicio externo, no hay "inteligencia artificial en línea", no hay telemetría. Si algún día se añadiera una función que necesitara Internet, vendría apagada de fábrica y documentada.

T — Tamice identificadores

Se busca en **cinco capas**:

- **Directos** — nombre, documento, historia clínica, teléfono, correo, dirección, póliza, firma, nombres de acompañantes y de profesionales.
 - **Indirectos** — edad exacta, fecha de nacimiento, fechas, ocupación, institución, aseguradora, localidad.
 - **Contextuales** — la combinación. *Mujer de 64 años, docente, de una ciudad concreta, atendida en tal hospital, tal día* puede identificar a una persona aunque cada dato por separado parezca inocuo. La herramienta cuenta cuántos de esos rasgos **sobreviven** al proceso y avisa cuando siguen siendo demasiados.
 - **Visuales** — texto escrito dentro de los píxeles de una imagen, códigos QR, códigos de barras.
 - **Técnicos** — todo lo que el archivo arrastra sin que usted lo vea. Ver sección 6.
-

4. Qué revisa, y la diferencia entre lo visible y lo invisible

Esta es la parte que más sorprende a quien no trabaja con documentos electrónicos.

Un archivo de Word **no es** lo que usted ve en pantalla. Es un paquete comprimido con más de una docena de piezas. Dentro pueden estar, sin aparecer en la hoja:

- el **autor** y el **último autor** que lo guardó (a veces, un correo institucional completo);
- la **empresa** y el nombre de la **plantilla** usada;
- **comentarios** con sus autores e iniciales;
- el **control de cambios**: texto que alguien borró y que sigue guardado en el archivo;
- **propiedades personalizadas** creadas por el sistema del hospital (número de paciente, médico tratante, correo de contacto);
- **encabezados y pies** que se repiten en todas las páginas;
- imágenes, objetos incrustados y, en algunos casos, macros.

En el caso de demostración que viene incluido, el nombre y la cédula de la paciente estaban **tres veces**: en el texto visible, en el texto borrado con control de cambios, y en las propiedades del archivo. Un documento del que usted hubiera "quitado el nombre" a mano seguiría llevándolos.

Un rectángulo negro encima de un texto no borra nada. En un PDF, ese texto sigue siendo seleccionable, copiable y extraíble por cualquier programa. Por eso ANONIMIZADOR **no tapa**: reconstruye el documento sin ese texto.

5. Qué pasa con la información clínica (la regla innegociable)

ANONIMIZADOR **no tiene autorización** para cambiar información clínica.

Antes de reescribir cualquier cosa, marca en el texto unas *zonas protegidas*: cifras con unidades, valores de laboratorio, dosis, signos vitales, medidas, términos anatómicos, lateralidad, medicamentos, procedimientos, diagnósticos, negaciones y grados de certeza. Si una transformación fuese a tocar una de esas zonas, **la transformación se bloquea**, se anota en la auditoría y el caso se manda a revisión humana. Prefiere no borrar un identificador antes que alterar un dato clínico.

Después de procesar, compara el antes y el después **valor por valor** y clasifica cada diferencia:

Clasificación	Significado
EXACT_MATCH	El dato clínico salió idéntico.
EXPECTED_TRANSFORMATION	Cambió porque formaba parte de algo que se decidió minimizar (p. ej. la edad).
UNEXPECTED_CHANGE	Un valor cambió sin motivo. Detiene la aprobación automática.
MISSING	Un dato clínico desapareció. Detiene la aprobación automática.
NEW_CONTENT	Apareció un dato que no estaba. Detiene la aprobación automática.

Si Hemoglobina: 8.9 g/dL sale como 8.8, como 9.8 o desaparece, el sistema **falla a propósito** y se niega a dar el documento por bueno. Si colon ascendente se convirtiera en colon sigmoide, lo mismo.

Además hay un detector de **información no soportada**: cualquier dato clínico que aparezca en el resultado y no exista en el original se marca como *POSIBLE ALUCINACIÓN / INFORMACIÓN NO SOPORTADA*. En V1 la reconstrucción es puramente determinista (sustituciones controladas), así que esto no debería ocurrir nunca; el detector existe para cazar un error del propio programa y para ser el guardián obligatorio si algún día se conectara un modelo de lenguaje.

6. Qué pasa con los metadatos

Se leen **todos** los que el formato permita, se listan en el informe y **ninguno se copia** al archivo nuevo. El archivo resultante se construye desde cero con propiedades neutras (autor vacío, título "Documento desidentificado", estado "DESIDENTIFICADO — PENDIENTE DE REVISIÓN", fecha neutra). Incluso el nombre del archivo de salida es neutro: si el original se llamaba HC_Lopez_Quintero.docx, el resultado se llama documento_desidentificado.docx.

7. Qué pasa con Word (.docx)

Se abre el paquete interno y se inspeccionan texto, encabezados, pies, tablas, cuadros de texto, notas al pie, comentarios (y sus autores), control de cambios (y sus autores), propiedades core / app / personalizadas, relaciones externas, imágenes, objetos incrustados y macros.

El resultado **se reconstruye desde cero**: párrafos, títulos y tablas, más dos anexos claramente rotulados con el texto de los encabezados y pies ya minimizados, para que no se pierda información clínica que viviera ahí.

No se copian al resultado: comentarios, control de cambios, macros, objetos incrustados, imágenes, propiedades ni miniatura. Está comprobado en las pruebas que los identificadores no aparecen **ni siquiera dentro del XML comprimido** del archivo generado.

8. Qué pasa con PDF

Se extraen texto, metadatos, XMP, anotaciones, campos de formulario, enlaces, imágenes y archivos incrustados; se detectan códigos QR renderizando cada página; y se buscan marcadores de contenido activo

(/JavaScript, /OpenAction, /Launch) que **nunca se ejecutan**.

Después se **escribe un PDF nuevo**, solo con el texto ya minimizado. No comparte un solo objeto con el original.

Terminado el archivo, el sistema **vuelve a abrirlo e intenta extraer identificadores**. Si reaparece alguno que se daba por eliminado, el resultado es FAIL, el documento no se aprueba y el informe dice **qué módulo falló**.

Limitación honesta: la versión reconstruida es **solo texto**. Las imágenes del PDF original no se transfieren (se avisa). Y si el PDF es un **escaneo** —una foto de un papel, sin texto extraíble— el sistema lo detecta, lo marca como **NO EVALUABLE** y le dice que no use ese resultado.

9. Qué pasa con las imágenes

Las imágenes son el punto más delicado, porque el nombre del paciente puede estar **pintado en los píxeles**, donde ningún "quitar metadatos" llega.

Lo que V1 hace:

- **Elimina EXIF y XMP** reescribiendo la imagen píxel a píxel en un archivo nuevo.
- **Detecta códigos QR y de barras**, los **destruye de verdad** (sobrescribe los píxeles) y **comprueba después** que ya no se detecta ninguno. Nunca abre la URL que contenga un QR.
- **Detecta regiones con aspecto de texto** mediante análisis morfológico y las lista.

Lo que V1 **no** hace por defecto, y por qué: sin OCR instalado no puede saber si esa franja de texto es "MARÍA FERNANDA LÓPEZ" o una escala de medida junto a la lesión. Como **no dañar la información clínica** manda sobre todo lo demás, **no borra a ciegas**: marca la región, sube el riesgo residual y pide revisión humana. Si usted decide que da igual tapar parte de la imagen, hay una casilla para redactar todas las regiones detectadas; entonces sí se destruyen los píxeles, y queda registrado en el informe.

Toda alteración de píxeles aparece en la auditoría.

10. Qué es el riesgo residual

Una escala de cinco niveles que **siempre viene con sus motivos**:

Nivel	Cuándo aparece
MUY BAJO	Reservado; V1 nunca lo emite, porque el riesgo nunca es cero.
BAJO	No quedaron identificadores detectables, los valores clínicos coinciden y el ataque al resultado no encontró nada.
MODERADO	Algo quedó marcado para revisión: un candidato incierto, texto dentro de una imagen, un cuasi-identificador que la finalidad pidió conservar, metadatos residuales.
ALTO	Falló una verificación: fuga adversarial, discrepancia clínica, contenido no soportado, o demasiados cuasi-identificadores combinados.
NO EVALUABLE	El documento no se pudo analizar de forma concluyente (por ejemplo, un PDF escaneado).

Ejemplo real de la salida:

Riesgo residual: **MODERADO**. — Se detectó texto dentro de una imagen que no pudo clasificarse de forma segura (6 regiones, sin OCR instalado). — Se detectaron códigos QR/barras; se destruyeron en el resultado y se verificó que no quedan.

Este puntaje no es una certificación legal. Es una ayuda para decidir cuánto mirar.

11. Por qué la revisión humana sigue siendo obligatoria

Porque hay cosas que ninguna regla puede resolver sola:

- Un caso clínico raro puede identificar al paciente **sin que aparezca ni un dato personal**: la enfermedad, la fecha y el servicio bastan si el diagnóstico es infrecuente.
- El programa no sabe quién más tiene acceso al contexto (colegas, familia, la propia institución).
- Los léxicos de nombres son listas humanas, siempre incompletas.
- Un texto quemado en una imagen puede ser información clínica esencial o el nombre del paciente, y hoy la herramienta no puede distinguirlos sin OCR.

Por eso todo documento sale en estado PENDING_REVIEW o REQUIRES_MANUAL_REVIEW, nunca aprobado. La aprobación (APPROVED_BY_HUMAN) solo puede registrarla una persona, y queda firmada con su nombre, comentario y fecha en el expediente.

12. Qué cubre V1

- Formatos: **TXT/MD, DOCX, PDF, PNG/JPG, XLSX**.
- Cinco capas de detección con reglas explícitas y auditables.
- Reconstrucción limpia (completa en TXT y DOCX; parcial en PDF, XLSX e imagen).
- Cuatro verificaciones automáticas independientes.
- Riesgo residual explicable + estados de revisión humana.
- Expediente de auditoría: `audit.json`, `transformation_matrix.csv`, `integrity_report.json`, `adversarial_scan.json`, `audit_report.html`, `RESUMEN.md`.
- Interfaz local en el navegador, con modo demostración de casos ficticios.
- 37 pruebas automáticas.
- Cero red, cero nube, cero IA.

13. Qué NO cubre V1

- **OCR** (requiere instalar Tesseract aparte).
- **DICOM**, PACS, HL7/FHIR.
- Imágenes dentro de DOCX/PDF: se reportan pero no se transfieren ni se analizan.
- PDF escaneado.
- Firmas manuscritas, sellos y logotipos.
- k-anonimato real sobre una población.
- Formatos: PPTX, ODT, RTF, CSV, EML/MSG, ZIP, audio, vídeo.
- Cualquier afirmación de cumplimiento legal.

El detalle completo, con el estado IMPLEMENTADO / PARCIAL / NO IMPLEMENTADO de cada elemento, está en `docs/COBERTURA_Y_LIMITACIONES.md`.

14. Próximos pasos (V2 y V3)

V2 — OCR local con redacción selectiva; transferir imágenes ya procesadas al documento reconstruido; PDF escaneado vía OCR; seudónimos coherentes en todo un expediente; más formatos; diccionarios ampliables desde la interfaz; firma criptográfica del expediente de auditoría.

V3 — DICOM completo, integración PACS/HIS, modelos NER clínicos y de visión como capa *sugere*nte (nunca decisoria), procesamiento masivo, autenticación y roles, cifrado y almacenamiento seguro, auditoría institucional, y revisión jurídica y regulatoria formal.

15. Versión en PDF

Este informe existe también como `docs/INFORME_ANONIMIZADOR.pdf`, generado localmente con la misma librería que ya usa el proyecto (reportlab), sin añadir ninguna dependencia nueva ni pasar por Internet. Para volver a generarlo tras editar el Markdown:

```
python docs/generar_pdf.py
```

El Markdown es siempre la fuente; el PDF es una copia para imprimir o circular.

Recuerde: ANONIMIZADOR reduce información identificable pero no garantiza anonimización absoluta. Revise siempre el documento antes de compartirlo. La aprobación final corresponde a una persona.